

# Pakiety stystystyczne

## Sprawozdanie 1

Paulina Muszyńska, Karolina Rakus

23 stycznia 2022

## 1 Wstęp

Ziemię zamieszkuje obecnie ponad 7 mld ludzi, a ilość produkowanego jedzenia pozwoliłaby na wykarmienie 10 mld osób. <sup>(1)</sup>. Równocześnie, blisko połowa zgonów wśród dzieci do piątego roku życia wynika z niedożywienia <sup>(2)</sup>. Niewystarczająca ilość składników mineralnych w diecie oraz zbyt małe ilości pożywienia, które dodatkowo często jest słabej jakości, przyczynia się do obniżenia odporności.

**Niedożywienie** często kojarzone jest jako stan organizmu, będący skutkiem niedoboru składników pokarmowych.

Rozszerzymy dane pojęcie definiując je jako stan organizmu, będący skutkiem *nieprawidłowego* doboru składników pokarmowych, zatem określenie "niedożywienie" w poniższej analizie będzie uwzględniać również takie miary jak nadwaga czy karłowatość.

## 2 Pytanie badawcze

- Czy występuje korelacja między wskaźnikiem przychodu a miarami niedożywienia?

---

<sup>1</sup><https://medium.com/@jeremyerdman/we-produce-enough-food-to-feed-10-billion-people-so-why-does-hunger-still-exist-8086d2657539>

<sup>2</sup><https://www.worldhunger.org/world-child-hunger-facts/>

## 3 Opis danych

### 3.1 Pochodzenie danych

Dane, z których korzystamy dostępne są poniżej:

<https://www.kaggle.com/ruchi798/malnutrition-across-the-globe>

### 3.2 Licencja danych

**Licencja CC0:** Domena Publiczna - oznacza to, że zgodnie z prawem autorskim dozwolone jest kopiowanie, modyfikowanie i rozpowszechnianie danych.

### 3.3 Opis zmiennych oraz ich możliwe wartości

Badanie było przeprowadzane od 1983 do 2019 roku. W badaniu brały udział dzieci w wieku od 0 do 59 miesięcy (czyli do 5 lat).

Miary, z których korzystamy przy klasyfikacji dzieci ze względu na nieprawidłowość w żywieniu wyglądają następująco:

- **Stunting** (karłowatość) - odnosi się do dzieci, które są za niskie na swój wiek. Dzieci należące do tej grupy mogą doznać poważnych uszkodzeń fizycznych oraz poznawczych, a skutki karłowatości mogą trwać całe życie, oraz wpłynąć na przyszłe pokolenie. Miara ta przedstawia procent dzieci poniżej dwóch standardowych odchyłeń od mediany wzrostu dla dzieci w swoim wieku.
- **Overweight** (nadwaga) - odnosi się do dzieci, które są za ciężkie w stosunku do swojego wieku i wzrostu. Nadwaga wśród dzieci wiąże się z poważnymi konsekwencjami w dorosłym życiu. Osoby te narażone są w większym stopniu na nadciśnienie, choroby serca czy cukrzycę. Miara przedstawia procent dzieci powyżej dwóch odchyłeń standardowych od mediany wagi do wzrostu.
- **Underweight** (niedowaga) - Dzieci, które ważą mniej niż powinny, ale jest to niebezpieczne w mniejszym stopniu niż w przypadku wyniszczenia lub skrajnego wyniszczenia. Miara przedstawia procent dzieci poniżej dwóch standardowych odchyłeń od mediany wagi do wzrostu dla dzieci w swoim wieku.

- **Wasting** (wyniszczenie) - odnosi się do dzieci, które ważą za mało niż powinny biorąc pod uwagę swój wiek i wzrost. Wyniszczenie jest skutkiem niedawnej szybkiej utraty wagi lub braku przyrostu masy ciała. Dziecko, które klasyfikuje się do tej kategorii ma zwiększone ryzyko chorób i śmierci, jednak leczenie na tym etapie jest możliwe. Miara przedstawia procent dzieci, których waga znajduje się pomiędzy minus dwoma a minus trzema odchyleniami standardowymi od mediany wagi do wzrostu populacji referencyjnej.
- **Severe wasting** (poważne wyniszczenie) - Poważne wyniszczenie to skrajny przypadek wyniszczenia. Poważnie wyniszczone dzieci są bardziej narażone na śmierć, ponieważ ich odporność na infekcje jest osłabiona przez brak składników odżywczych. Miara przedstawia procent dzieci, które są poniżej minus trzech odchyłeń standardowych od mediany masy ciała do wzrostu dla dzieci w swoim wieku.

Dodatkowo, mamy do dyspozycji zmienną **Income Classification** (klasyfikator przychodu) informujący o zamożności danego kraju. Klasyfikator przychodu może przyjmować cztery wartości: 0, 1, 2 lub 3, które oznaczają kolejno dla danego państwa: niski przychód, średnie-niski przychód, średnio-wysoki przychód, wysoki przychód. Poziom dochodu szacowany jest w oparciu o DNB na mieszkańca (DNB to dochód narodowy brutto - całkowity dochód otrzymany przez dany kraj w ciągu roku).

*gyig*

## 4 Przygotowanie danych

### 4.1 Pobranie danych

```
data_mal = read.csv('malnutrition-estimates.csv')
colnames(data_mal)
```

Po pobraniu danych, przyjrzyjmy się nazwom kolumn.

##	[1]	"X"	"ISO.code"	"Country"
##	[4]	"Survey.Year"	"Year"	"Income.Classification"
##	[7]	"LDC"	"LIFD"	"LLDC.or.SID2"

```
## [10] "Survey.Sample..N." "Severe.Wasting" "Wasting"
## [13] "Overweight" "Stunting" "Underweight"
## [16] "Notes" "Report.Author" "Source"
## [19] "Short.Source" "U5.Population...000s."
```

## 4.2 Usunięcie niepotrzebnych kolumn

Niektóre kolumny w naszych danych zawierają informacje, które nie będą potrzebne do analizy danych pod kątem postawionego pytania badawczego. Z tego też powodu usuniemy następujące kolumny:

- X,
- ISO.code
- Survey.Year
- Survey.Sample..N
- Report.Author
- Source
- Short.source
- U5.Population...000s.

```
drop <- c("X", "ISO.code", "Survey.Year", "Survey.Sample..N.",
          "Notes", "Report.Author", "Source", "Short.Source",
          "U5.Population...000s.")
data_mal = data_mal[,!(names(data_mal) %in% drop)]
```

W kolejnym etapie zmienimy nazwy kolumn na bardziej "skondensowane".

```
id1 = grep("Income.Classification", colnames(data_mal)) #indeks
colnames(data_mal)[id1] <-"Income"
id2 = grep("LLDC.or.SID2", colnames(data_mal))
colnames(data_mal)[id2] <- "LLDC.SIDS"
```

Przjrzyjmy się zmiennym kategoriowym. Dla niektórych z nich możemy zmienić etykiety.

```
data_mal$Income[data_mal$Income==0] <- "Low Income"
data_mal$Income[data_mal$Income==1] <- "Lower Middle Income"
data_mal$Income[data_mal$Income==2] <- "Upper Middle Income"
data_mal$Income[data_mal$Income==3] <- "High Income"

data_mal$LLDC.SIDS[data_mal$LLDC.SIDS==1] <- "LLDC"
data_mal$LLDC.SIDS[data_mal$LLDC.SIDS==2] <- "SIDS"
data_mal$LLDC.SIDS[data_mal$LLDC.SIDS==0] <- "Others"
```

### 4.3 Dodanie nowej kolumny

Opracowywane przez nas dane dotyczą krajów. By móc wyciągać wnioski oraz spostrzeżenia w bardziej globalnym sensie, będziemy potrzebować dodatkowej zmiennej określającej **kontynent**. W tym celu posłużymy się biblioteką *countrycode*, przy pomocy której stworzymy nową kolumnę, która korzystając z nazwy kraju dobierze kontynent, na którym ten kraj się znajduje.

```
# dodanie nazwy kontynentu bazując na nazwie kraju
df <- data.frame(country = c(data_mal$Country))
data_mal$Continent <- countrycode(sourcevar = df[, "country"],
                                   origin = "country.name",
                                   destination = "continent")
```

### 4.4 "Podgląd" danych

Przjrzyjmy się teraz pierwszym sześciu obserwacjom.

```
head(data_mal)
```

	Country	Year	Income	LDC	LIFD	LLDC.SIDS
1	AFGHANISTAN	1997	Low Income	1.00	1.00	LLDC
2	AFGHANISTAN	2004	Low Income	1.00	1.00	LLDC
3	AFGHANISTAN	2013	Low Income	1.00	1.00	LLDC
4	AFGHANISTAN	2018	Low Income	1.00	1.00	LLDC
5	ALBANIA	1997	Upper Middle Income	0.00	0.00	Others
6	ALBANIA	2000	Upper Middle Income	0.00	0.00	Others

Tabela 1: Pierwsze 6 obserwacji (kolumny 1:6)

	Severe.Wasting	Wasting	Overweight	Stunting	Underweight	Continent
1		18.20	6.50	53.20	44.90	Asia
2	3.50	8.60	4.60	59.30	32.90	Asia
3	4.00	9.50	5.30	40.40	24.60	Asia
4	1.60	5.10	4.10	38.20	19.10	Asia
5		8.10	9.50	20.40	7.10	Europe
6	6.20	12.20	30.10	39.20	17.00	Europe

Tabela 2: Pierwsze 6 obserwacji (kolumny 7:12)

## 4.5 Braki danych

W tabeli 2 możemy zauważyć brakujące obserwacje. Zobaczmy jak to wygląda w całym zbiorze danych.

```
sapply(X = data_mal, FUN = function(x) sum(is.na(x)))
```

```
##      Country      Year      Income      LDC      LIFD
##      0          0          0          0          0
##      LLDC.SIDS Severe.Wasting      Wasting      Overweight      Stunting
##      0          228          47          136          37
##      Underweight      Continent
##      22          0
```

Jako że nasz zbiór zawiera dane zmienne w czasie, na przestrzeni 36 lat, nierozsądnym byłoby uzupełnianie ich poprzez średnią czy medianę. Ponieważ dane np w 1985 roku mogą znacznie różnić się z sytuacją, którą zastaniemy w np 1015 roku. Sprawdźmy czy mamy takie państwo dla którego amplituda najwcześniejszej i najpóźniejszej obserwacji wynosi maksymalnie 5 lat. Możemy wtedy pokusić się o policzenie średniej danego parametru grupując według państw i uzupełnić braki danych. Okres 5 lat nie generuje aż tak duży zmian w porównaniu do 36 lat. Kolejnym pomysłem w przypadku

braku danych dla pojedynczych lat byłoby przypisanie wartości z najbliższego roku.

```
data_mean <- group_by(data_mal, Country) %>%
  summarise(Country = unique(Country),
            income=unique(Income),
            Severe.Wasting = mean(Severe.Wasting, na.rm = TRUE),
            Wasting = mean(Wasting, na.rm = TRUE),
            Overweight= mean(Overweight, na.rm = TRUE),
            Stunting = mean(Stunting, na.rm = TRUE),
            Underweight = mean(Underweight, na.rm = TRUE),
            Year.amp = max(Year) - min(Year))
head(data_mean)
```

	Country	income	Severe.Wasting	Wasting
1	AFGHANISTAN	Low Income	3.03	10.35
2	ALBANIA	Upper Middle Income	4.08	7.76
3	ALGERIA	Upper Middle Income	2.73	5.94
4	ANGOLA	Lower Middle Income	2.40	6.93
5	ARGENTINA	Upper Middle Income	0.20	2.15
6	ARMENIA	Upper Middle Income	1.60	3.94

Tabela 3: Średnie paramterów według państw (kolumny 1:4)

	Overweight	Stunting	Underweight
1	5.12	47.77	30.38
2	20.80	24.16	7.70
3	12.83	19.57	7.34
4	2.55	42.63	23.60
5	11.12	10.02	2.60
6	13.62	16.12	3.48

Tabela 4: Średnie paramterów według państw (kolumny 5:7)

```
sapply(X = data_mean, FUN = function(x) sum(is.na(x)))
```

##	Country	income	Severe.Wasting	Wasting	Overweight
##	0	0	12	2	3
##	Stunting	Underweight	Year.amp		
##	1	2	0		

Pomimo pogrupowania danych według państw i obliczenia średnich, nadal obserwujemy braki obserwacji, oznacza to że dla niektórych państw mamy braki danych na przestrzeni całego okresu czasu.

Zobaczmy teraz czy jest jakieś państwo (wśród krajów, dla których występuje brak danych), dla którego amplituda czasu badania jest mniejsza niż 5 lat.

```
data_with_NA <- data_mal[rowSums(is.na(data_mal)) > 0,]
countries_with_NA <- c(unique(data_with_NA$Country))
data_mean_na <- data_mean[data_mean$Country %in%
                           countries_with_NA,]
data_mean_5 <- data_mean_na[data_mean_na$Year.amp < 5
                             & data_mean_na$Year.amp > 0,]
country_5 <- data_mean_5$Country
length(country_5)

## [1] 0
```

Widzimy, że nie mamy wśród naszych obserwacji żadnego takiego państwa. Zatem decydujemy się na zostawienie danych, wraz z brakami danych.

Jeszcze jednym pomysłem, mogłaby być analiza poszczególnych państw. Wtedy należałoby przyjrzeć się dokładnie jakie lata obserwowano i być może byłyby takie państwa dla których odległości między poszczególnymi datami, w których dokonywano pomiarów są na tyle małe, że nie byłoby błędem zastąpienie braku danych np. najbliższym (w sensie czasu) pomiarem.

## 5 Analiza danych

### 5.1 Podstawowe statystyki zmiennych

```
summary(data_mal)
```



	Country	Year	Income	LDC
X	Length:924	Min. :1983	Length:924	Min. :0.0000
X.1	Class :character	1st Qu.:1996	Class :character	1st Qu.:0.0000
X.2	Mode :character	Median :2004	Mode :character	Median :0.0000
X.3		Mean :2004		Mean :0.3496
X.4		3rd Qu.:2011		3rd Qu.:1.0000
X.5		Max. :2019		Max. :1.0000

Tabela 5: Podstawowe statystyki (kolumny 1:4)

	LIFD	LLDC.SIDS	Severe.Wasting	Wasting
X	Min. :0.0000	Length:924	Min. : 0.000	Min. : 0.000
X.1	1st Qu.:0.0000	Class :character	1st Qu.: 0.800	1st Qu.: 2.900
X.2	Median :0.0000	Mode :character	Median : 1.600	Median : 5.900
X.3	Mean :0.4242		Mean : 2.192	Mean : 6.956
X.4	3rd Qu.:1.0000		3rd Qu.: 2.900	3rd Qu.: 9.700
X.5	Max. :1.0000		Max. :12.900	Max. :25.300
X.6			NA's :228	NA's :47

Tabela 6: Podstawowe statystyki (kolumny 5:8)

## 5.2 Histogramy

Sprawdźmy jak wyglądają histogramy poszczególnych współczynników niedożywienia tj. poważne wyniszczenie, wyniszczenie, nadwaga, zahamowanie wzrostu, niedowaga.

```
hSW <- ggplot(data=data_mal, aes(Severe.Wasting)) +
  geom_histogram(aes(y =..density..),
                 breaks=seq(0,
                             max(data_mal$Severe.Wasting, na.rm=T),
                             by = 0.8),
                 col="blue",
                 fill="blue",
                 alpha=.2) +
  geom_density(col=2, lwd=0.75) +
  labs(x="% dzieci poniżej 5 roku życia,
        \n dla których zaobserwowano poważne wyniszczenie",
        y="Częstość")
```

Podsumowując informacje uzyskane z podstawowych statystyk oraz z wy-

	Overweight	Stunting	Underweight	Continent
X	Min. : 0.000	Min. : 0.00	Min. : 0.000	Length:924
X.1	1st Qu.: 2.900	1st Qu.:16.65	1st Qu.: 4.925	Class :character
X.2	Median : 5.500	Median :29.20	Median :13.400	Mode :character
X.3	Mean : 6.435	Mean :29.06	Mean :15.841	
X.4	3rd Qu.: 8.700	3rd Qu.:40.20	3rd Qu.:23.100	
X.5	Max. :30.100	Max. :73.60	Max. :66.800	
X.6	NA's :136	NA's :37	NA's :22	

Tabela 7: Podstawowe statystyki (kolumny 9:12)

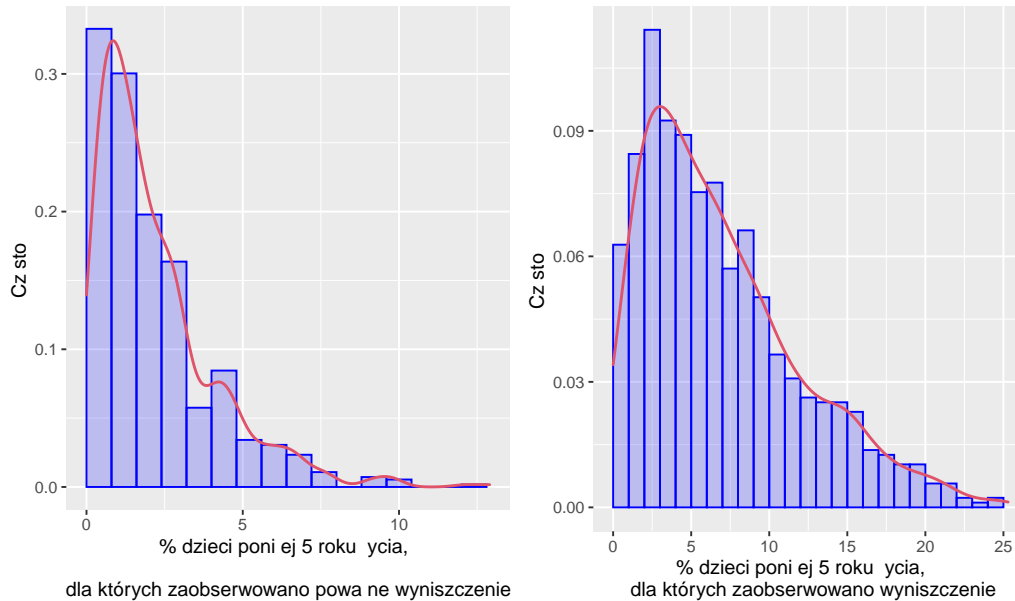
kresów histogramów, przyjrzyjmy się każdemu ze współczynników niedożywienia:

- Poważne wyniszczenie (Severe.Wasting) W skrajnych przypadkach osiąga nawet 12%, jednak średnio 2% dzieci do piątego roku życia cierpi na poważne wyniszczenie.
- Wyniszczenie (Wasting) Na wyniszczenie cierpi średnio 7% dzieci poniżej piątego roku życia. Najwyższy wskaźnik procentowy wynosi 25%.
- Nadwaga (Overweight) Na nadwagę cierpi średnio 6% dzieci, a w kraju najbardziej dotkniętym nadwagą dzieci - aż 30%,
- Zahamowanie wzrostu (Stunting) Zahamowanie wzrostu w porównaniu do poprzednich wskaźników charakteryzuje się innym rozkładem. Niestety nie maleje tak szybko jak pozostałe. Występuje w dużo intensywniejszej skali. Średnia wynosi ok 30%, a skrajny przypadek to 73%.
- Niedowaga (Underweight) Na niedowagę średnio cierpi 15% dzieci. W najgorszym wypadku jest to aż 67 % dzieci.

### 5.3 Analiza w oparciu o współczynnik przychodu

Na początek zastanówmy się, jak wygląda rozkład krajów, w zależności od współczynnika przychodu. Dla każdego kraju mamy parę rekordów - sprawdźmy najpierw, czy istnieje kraj, dla którego kategoria przychodu zmieniła się na przestrzeni lat.

Histogramy dla zmiennych poważne wyniszczenie, wynieszczenie



Rysunek 1: Histogramy zmiennych poważne wyniszczenie, wynieszczenie.


```
df <- group_by(data_mal, Country)%>%
  summarise(inc=unique(Income))
length(df$Country) == 152

## [1] TRUE
```


Zatem przychód jest wartością stałą dla danego państwa na przestrzeni lat.

```
# wykres wszystkich krajów w zależności od parametru Income

data_mal_income_percentage <- data_mal %>%
  group_by(Income) %>%
  count() %>%
  ungroup() %>%
  mutate(per=round(`n`/sum(`n`), 4)) %>%
  arrange(Income)
```



Rysunek 2: Histogramy zmiennych nadwaga, zahamowanie wzrostu



Rysunek 3: Histogram zmiennej niedowaga

```

data_mal_income_percantage$label <-
  scales::percent(data_mal_income_percantage$per)


data_mal_income_percantage$Income[data_mal_income_percantage$
  Income == "Low Income"] <- "Niski"
data_mal_income_percantage$Income[data_mal_income_percantage$
  Income == "Lower Middle Income"] <- "Średnio-niski"
data_mal_income_percantage$Income[data_mal_income_percantage$
  Income == "Upper Middle Income"] <- "Średnio-wysoki"
data_mal_income_percantage$Income[data_mal_income_percantage$
  Income == "High Income"] <- "Wysoki"

data_mal_income_percantage$Income <-
  factor(data_mal_income_percantage$Income,
    levels = c("Niski", "Średnio-niski",
      "Średnio-wysoki", "Wysoki"))

# wykres
kolo_plot <- ggplot(data_mal_income_percantage,
  aes(x="", y=per, fill=Income)) +
  geom_col(width = 1, size = 1, color = "white") +
  geom_text(aes(label = label),
    position = position_stack(vjust = 0.5)) +
  coord_polar(theta="y", 0) +
  theme_void() +
  scale_fill_manual(values =
    c("#f8766d", "#7cae00", "#00bfc4", "#c77cff")) +
  theme_classic() +
  theme(axis.line = element_blank(),
    axis.text = element_blank(),
    axis.ticks = element_blank(),
    axis.title.x = element_blank(),
    axis.title.y = element_blank(),
    plot.title = element_text(hjust = 0.5)) +
  guides(fill=guide_legend(title="Kategoria przychodu: "))

```

### Podział państw ze względu na przychód



Rysunek 4: Wykres kołowy częstości państw z danym przychodem

```
kolow_plot + ggtitle("Podział państw ze względu na przychód")
```

Widzimy, że najwięcej państw klasyfikowanych jest jako kraje o niższej lub wyższej średnim przychodzie.

Następnie histogramy przychodu dla poszczególnych kontynentów.

```
### podział na kontynenty
asia <- data_mal[data_mal$Continent == "Asia", c(0:12)]
africa <- data_mal[data_mal$Continent == "Africa", c(0:12)]
europe <- data_mal[data_mal$Continent == "Europe", c(0:12)]
```

```

americas <- data_mal[data_mal$Continent == "Americas", c(0:12)]
oceania <- data_mal[data_mal$Continent == "Oceania", c(0:12)]
### kontynenty bz powtórek krajów
asia_countries_and_income <-
  asia[!duplicated(asia$Country), ]
africa_countries_and_income <-
  africa[!duplicated(africa$Country), ]
europe_countries_and_income <-
  europe[!duplicated(europe$Country), ]
americas_countries_and_income <-
  americas[!duplicated(americas$Country), ]
oceania_countries_and_income <-
  oceania[!duplicated(oceania$Country), ]

```

Widzimy , że rozkład krajów ze względu na przychód w Azji przypomina rozkład ogólny. W Europie oraz w Oceanii nie ma ani jednego kraju, który klasyfikowałby się jako państwo o niskim przychodzie. W Ameryce najwięcej państw określonych jest jako kraje o wyżej średnim przychodzie. Najgorzej sytuacja wygląda w Afryce - widzimy, że zdecydowana większość państw uzyskuje niski, lub niżej średni przychód.

## 5.4 Współczynniki niedożywienia a przychód

Zastanówmy się jak przychód wpływa na każdy ze współczynników niedożywienia.

```


positions <- c("Niski", "Średnio-niski",
              "Średnio-wysoki", "Wysoki")

data_mean_income <- data_mean[2:7]
colnames(data_mean_income) <-
  c("income", "Poważne wyniszczenie", "Wyniszczenie", "Nadwaga",
    "Zahamowanie wzrostu", "Niedowaga" )
data_mean_income <- reshape2::melt(data_mean_income,
                                   id.var='income')

data_mean_income <- group_by(data_mean_income, income, variable) %>%

```

### Podział państw ze względu na przychód



Rysunek 5: Podział państw ze względu na przychód




```

summarise(value = sum(value, na.rm = TRUE))

ggplot(data_mean_income, aes(fill=variable, y=value, x=income)) +
  geom_bar( stat='identity', position = "dodge") +
  labs(title = "Współczynniki niedożywiania a przychód",
       x="Przychód", y="Suma", fill="Niedożywienie") +
  theme(plot.title = element_text(size=22, hjust = 0.5, vjust=0.4),
        axis.title.x = element_text(size = 12),
        axis.title.y = element_text(size = 12)) +
  scale_x_discrete(limits = positions)

```



Rysunek 6: Zależność między przychodem a współczynnikami niedożywienia

Z rysunku 6 odczytujemy, że w krajach z wysokim dochodem problem niedożywienia jest zdecydowanie mniejszy. Niezależnie od klasyfikacji przychodów obserwujemy największy procentowo udział problemu zahamowania wzrostu. Dla krajów z niskim, średnio-niskim i średnio-wysokim przychodem drugim najbardziej dotkliwym problemem jest niedowaga. W krajach o najwyższym przychodzie występuje stosunkowo niski procent współczynnika

nadwagi, który z kolei jest najwyższy dla krajów o średnio-wysokim przychodzie.

## 5.5 Mapy

Przenieśmy teraz nasz badany problem na mapę, aby zobaczyć jakich krajów on dotyczy. W tym celu skorzystamy z bazy danych *world*. Najpierw przyjrzymy się mapie wskaźnika przychodu.

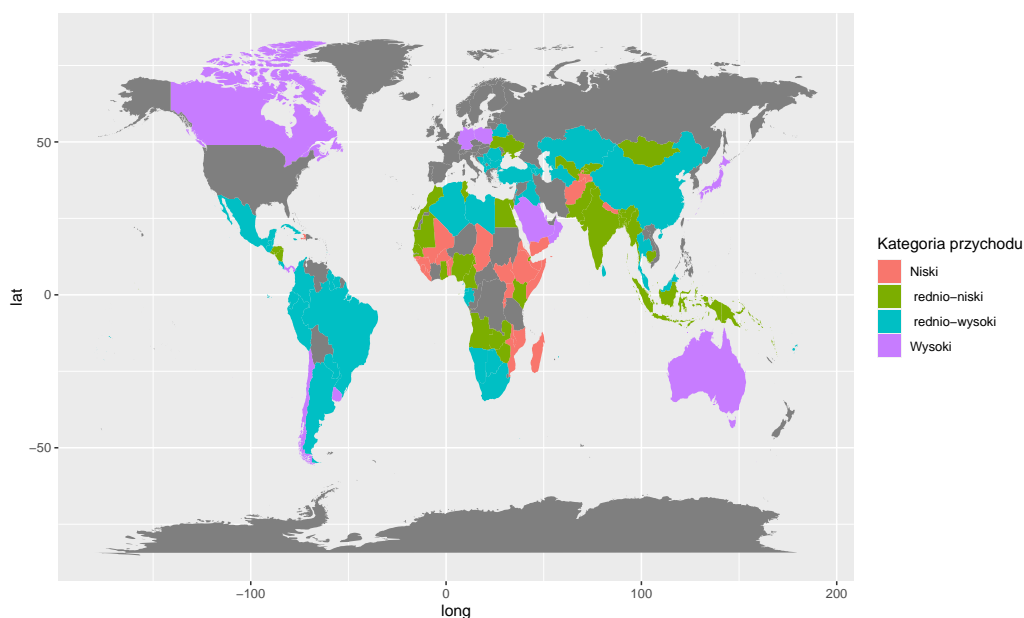
```
world <- map_data("world")
world$region = toupper(world$region)
world %>%
  merge(data_mean, by.x = "region",
        by.y = "Country", all.x = T) %>%
  arrange(group, order) %>%
  ggplot(aes(x = long, y = lat,
             group = group, fill = income)) +
  labs(fill="Kategoria przychodu") +
  geom_polygon() +
  scale_fill_discrete(limits = positions)
```

Zobaczmy jak konkretny aspekt niedożywienia występuje w skali światowej.

```
world <- map_data("world")
world$region = toupper(world$region)
world %>%
  merge(data_mean, by.x = "region",
        by.y = "Country", all.x = T) %>%
  arrange(group, order) %>%
  ggplot(aes(x = long, y = lat,
             group = group, fill = Powazne.wyniszczenie)) +
  geom_polygon() + scale_fill_gradient(low='blue', high='red')
```

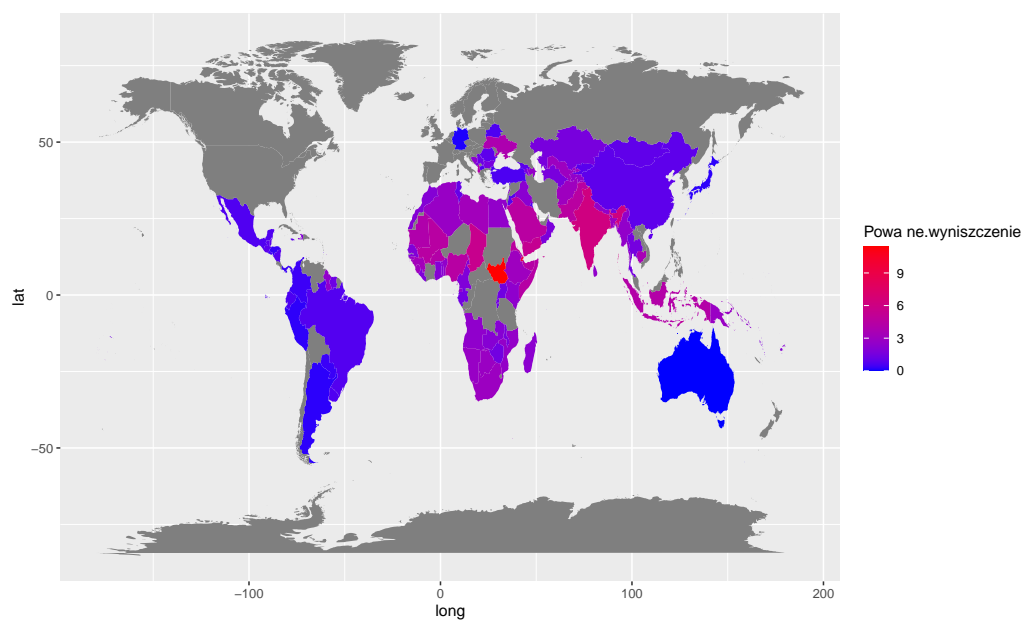
## 6 Podsumowanie

Mimo pędzącego świata i widocznego w każdym aspekcie postępu technologicznego musimy pamiętać, że w dalszym ciągu na świecie jest wiele miejsc,

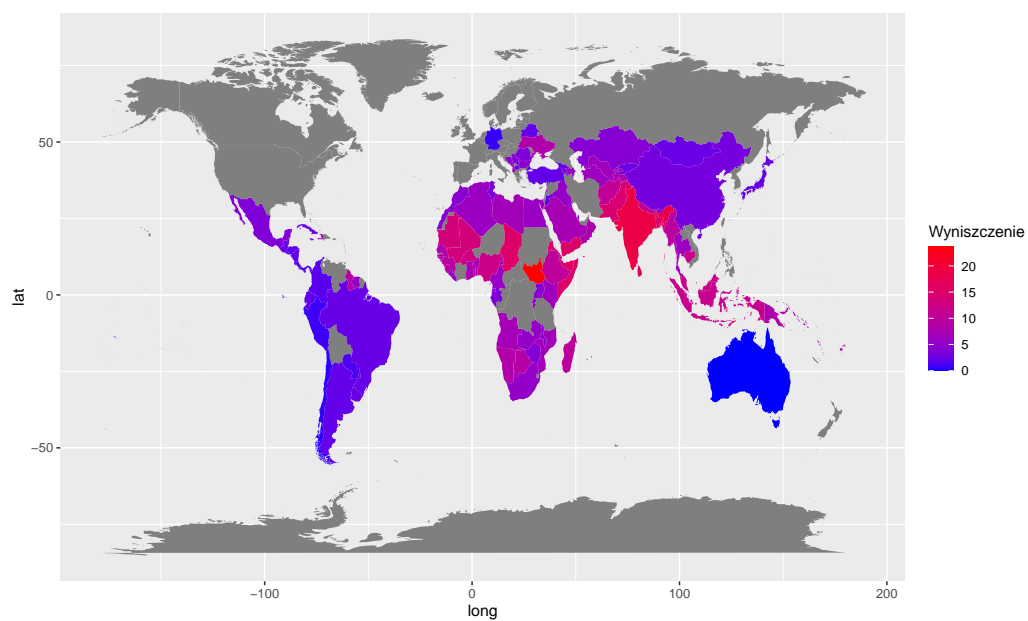


Rysunek 7: Współczynnik przychodu zobrazowany na mapie

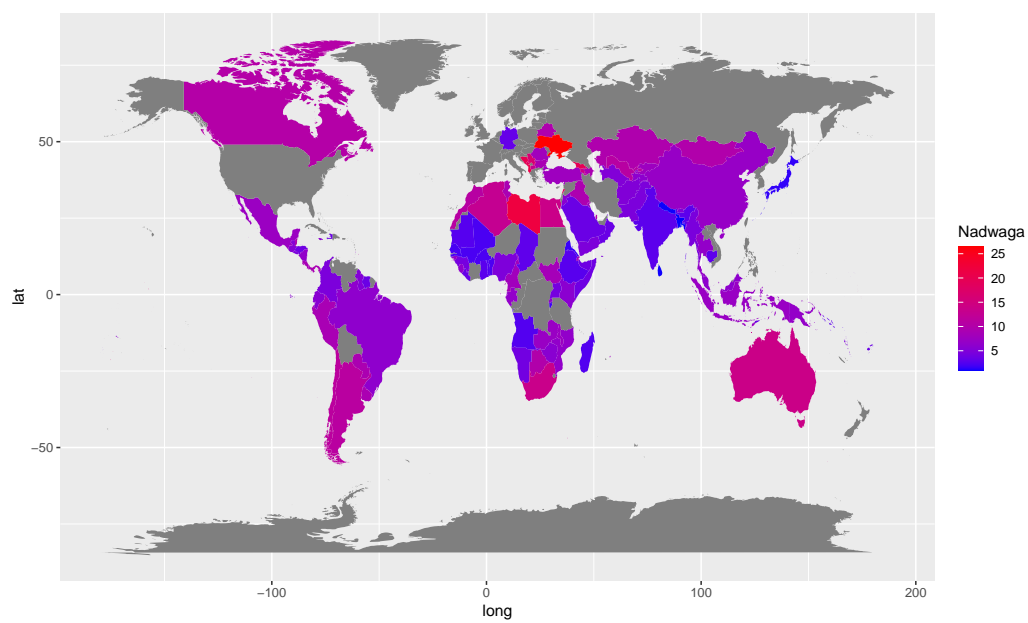
w których ludzie cierpią z powodu skrajnego ubóstwa. Na podstawie przeprowadzonej analizy danych widzimy silną zależność między niskim przychodem kraju, a wysokimi wartościami współczynników, mówiących o tym, że dzieci ważą zbyt mało. Odwrotną zależność można zauważyć w przypadku współczynnika mówiącego o nadwadze - najczęściej przypadków dzieci otyłych jest w krajach o średnio-niskim i średnio-wysokim przychodzie. Co ciekawe, gdy zwrócimy uwagę na miarę "karłowatość" - w tym przypadku wysokie wartości uzyskiwane są dla krajów o niskim, średnio-niskim i średnio-wysokim przychodzie.



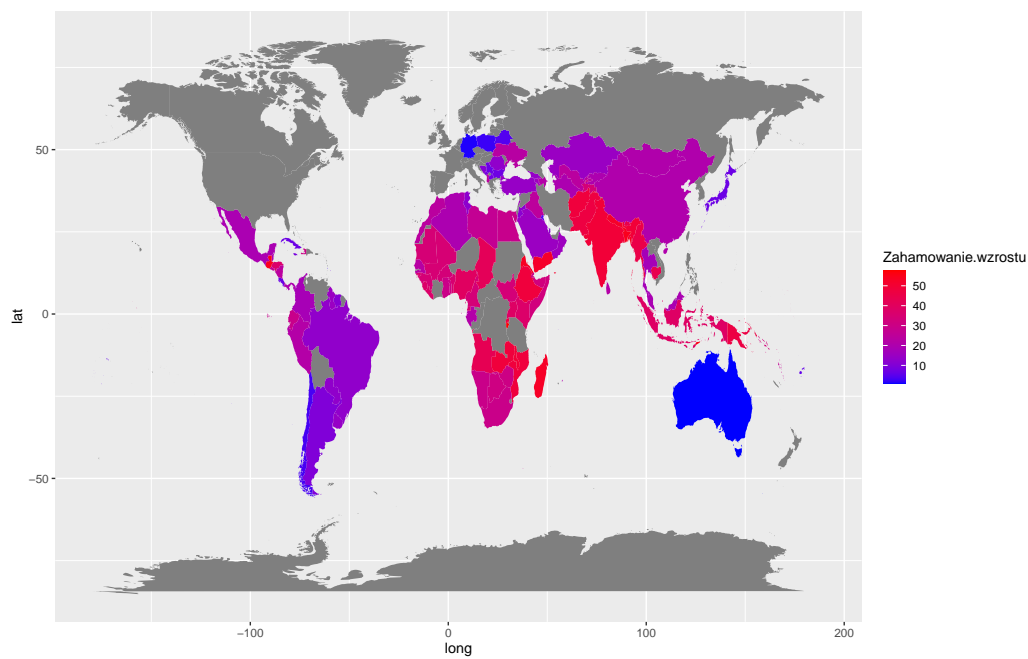
Rysunek 8: Klasyfikacja państw ze względu na przychód.



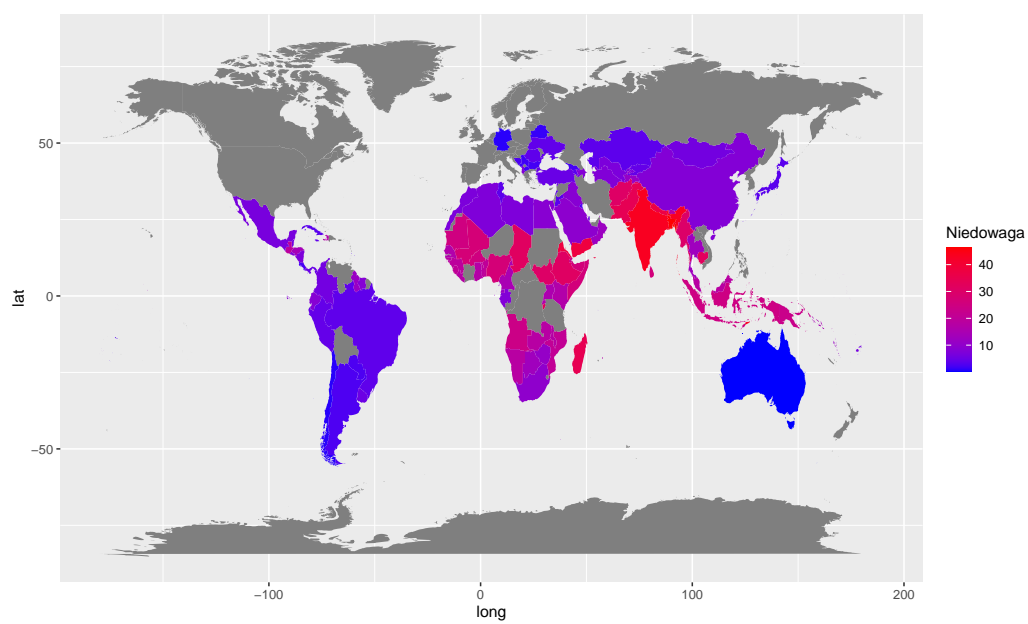
Rysunek 9: Współczynnik wyniszczenia w skali świata



Rysunek 10: Współczynnik nadwagi w skali świata



Rysunek 11: Współczynnik zachamowania wzrostu w skali świata



Rysunek 12: Współczynnik niedowagi w skali świata